## Data Mining Project 2 Report 309552007 袁鈺勛

#### A. Readme

Argument	Description	Default	Туре	
l,learning_rate	Learning rate	0.1	Float	
r,regularization	0: without L2 regularization, 1: with L2 regularization	0 (0-1)	Int	
p,penalty	Hyperparameter of regularization	1.0	Float	
tun				
<b>Run</b> Argument	Description	Default		
	Description  Learning rate	Default		
Argument				
Argument	Learning rate	0.1		
Argument I,learning_rate r,regularization	Learning rate  0: without L2 regularization, 1: with L2 regularization	0.1		

Program file 中有一個 LogisticRegression class,"-l" 可以控制 learning rate,"-r"可以控制是否要使用 regularization,"-p"可以控制 regularization 的 hyperparameter。在 run program 的時候除了上面提到的三個 argument 之外,還有"-m"可以控制是要做 cross validation 還是做 prediction,"-v"可以控制是否要 print 一些額外的 information。Training data 和 testing data 以及 submission 這三個 file 要放在和 program file 同一層的 data directory下。做 完 prediction 的 result 會輸出成 result.csv。

### **B.** Preprocessing

上圖為"predict\_info\_fixer" function,會將共病症、抗生素、細菌的缺格補上0,並且幫共病症各種類別給上特定的數值,抗生素和細菌則是非0的話給1,0的話就給0。

上圖為"predict\_tpr\_fixer" function,他會將 training data 做標準化後,將標準化時算出的 mean 和 variance 用來將 testing data 標準化,以避免 feature 間單位和數值區間的不同。

#### C. Feature Selection

```
# Use mutual information to select top k features
list_of_col = SelectKBest(mutual_info_classif, k=k).fit(training_data, training_target).get_support(indices=True)
features = list(map(list(training_data).__getitem__, list_of_col))
return features
```

利用 mutual information 來取出前 k 個和 label 最相關的 feature。

#### **D.** Model Construction

```
# Calculate parameters
num_of_data = len(training_data)

# Set up $\phi$ and group
group = training_data['Target'].to_numpy().reshape((num_of_data, 1))
del training_data['Target']
self.features = list(training_data)
num_of_features = len(self.features)
phi = np.ones((num_of_data, num_of_features + 1))
phi[:, 1:] = training_data.to_numpy()

# Get gradient descent result
self.omega = self.gradient_descent(phi, group, num_of_features)
return self.omega
```

上圖為 model 的"fit" function,他會先取出每個 data entity 對應到的 label,以及取出 training 所用到的 feature,而且會將 data 組成一個新的 phi 用於 gradient descent 的計算。

## return phi.T.dot(expit(phi.dot(omega)) - group)

上兩張圖分別為 model 的"gradient\_descent" function 和"get\_delta\_j" function,當 gradient descent 收斂的時候便可以得到 optimal weight omega,而且收斂的方式區分為有 regularization 以及沒有 regularization,兩種方法都會使用 momentum term。

```
# Calculate parameters
testing_data = test_data[self.features]
num_of_data = len(testing_data)
num_of_features = len(list(testing_data))

# Set up Φ
phi = np.ones((num_of_data, num_of_features + 1))
phi[:, 1:] = testing_data.to_numpy()

# Get results of gradient descent
weight = weight.reshape((len(weight), 1))
result = expit(phi.dot(weight))
result[result > 0.5] = 1
result[result < 0.5] = 0
result = result.reshape(num_of_data).astype(int)</pre>
```

上圖為 model 的"prediction" function,他會將 testing data 組成的 phi 和 weight 餵給 logistic function,機率大於等於 0.5 的就歸類為 label 1,小於 0.5 的就歸類給 label 0。

```
# Calculate parameters
testing_data = test_data[self.features]
num_of_data = len(testing_data)
num_of_features = len(list(testing_data))

# Set up 
phi = np.ones((num_of_data, num_of_features + 1))
phi[:, 1:] = testing_data.to_numpy()

# Get results of gradient descent
result = expit(phi.dot(weight)).reshape(num_of_data)

return result
```

上圖為 model 的"pred\_prob" function,同樣會將 testing data 以及 weight 餵給 logistic function,並且回傳 data 可能為 label 1 的機率。

#### E. Validation


# # Setup K fold skf = RepeatedStratifiedKFold(n\_repeats=10, random\_state=0)

使用 stratified k-fold 來驗證,預設 5個 fold,跑 10次來測試。


```
for train_index, test_index in skf.split(training_data, training_target):
    # Get training set and testing set
    data_train, target_train = training_data.iloc[train_index.tolist()], training_target.iloc[
        train_index.tolist()]
    data_test, target_test = training_data.iloc[test_index.tolist()], training_target.iloc[test_index.tolist()]

# Use training set to select features
for k in range(2, total_features):
    info_log(f' = Iteration: {iteration}, Num of features: {k} = ')
    features = feature_selection(data_train, target_train, k)
```

每次從 training data set 中取出 training data 以及 testing data, 並利用 training data 選取要使用的 feature。




上面三張圖為沒有 regularization 的 validation 結果,左上圖為取不同數量的 feature 得到的各自平均 accuracy 以及平均 fl-score,右上圖即為左上圖的視覺化,第三張即是不同數量 feature 的情況底下得到的平均 weight。




上面三張圖為有 regularization 的 validation 結果,可以看出他相對沒有 regularization 的結果較為穩定,所以在做 prediction 時是採用有 regularization 的結果。

#### F. Prediction

上圖是 model 的"visualize" function,他會將 fit 得到的 feature 以及對應的 weight 視覺化成下面兩張圖類型的 horizontal bar chart。



上圖為沒有 regularization 方式做 prediction 後得到的 feature weight。



上圖為有 regularization 方式做 prediction 後得到的 feature weight。